

LeNet5实验报告

计算机科学与技术 2012522 郭坤昌

摘要

本实验主要通过以numpy实现LeNet5，并完成基于MNIST数据集的手写数字识别。首先介绍实现LeNet5的基本网络结构和参数，接着介绍具体网络的实现——网络模型和各层的前向传播、反向传播实现，最后介绍训练过程及结果。完整代码详见：[Lenet5](#)

关键词

LeNet5；卷积；池化；BP算法；


网络结构与参数

详细网络参数如下表：

层号	名称	输入 (高度,宽度,通道)/特征图数	卷积核/池化核 (高度,宽度,数量)	(步长,补白)	输出 (高度,宽度,通道)/特征图数
1	输入层	None	None	None	(28,28,1)
2	卷积层1	(28,28,1)	(5,5,6)	(1,2)	(28,28,6)
3	池化层1	(28,28,6)	(2,2,1)	(2,0)	(14,14,6)
4	卷积层2	(14,14,6)	(5,5,16)	(1,0)	(10,10,16)
5	池化层2	(10,10,16)	(2,2,1)	(2,0)	(5,5,16)
6	全连接层1	(5,5,16)	(5,5,120)	(1,0)	120
7	全连接层2	120	None	None	84
8	输出层	84	None	None	10

- 输入输出中，为突出网络结构，在表示时略去了输入图片的数量这一特征
- 这里没有明确指明卷积层和全连接层激活函数的选择，本实验使用ReLU函数进行激活
- 在本实验中，由于输入图片像素为 28×28 ，因此设置卷积层1的 `Padding=2`，则输出图片大小 $(28 + 2 \times 2 - 5) / 1 + 1 = 28$ ，保证了输出规模与原模型中输出规模一致

图示如下：



代码实现细节

首先给出Lenet5网络的整体结构代码，接下来介绍各层设计，最后介绍训练过程和结果分析代码

LeNet5

网络结构大致遵循第三部分介绍的LeNet5的基本结构，并设置各层相应参数。在这里，卷积层和全连接层的激活函数选用ReLU函数

1. 第一层为卷积层。卷积核大小 5×5 ，步长为1，补白大小为2，输入通道为1，输出通道为6。这里将补白大小设置为2，即可将单张 28×28 大小的图片在卷积过后，仍能以下一层需要的 28×28 的大小提供。
2. 第二层为池化层。池化核大小为 2×2 ，步长为2。这样单张大小为 28×28 的图片在池化过后大小为 14×14 。本实验使用最大池化，以保存更多纹理信息
3. 第三层为卷积层。卷积核大小为 5×5 ，步长为1，补白为0，输入通道数6，输出通道数16。在原论文中，Yann LeCun特别设计了盖层的卷积方式，不是每个卷积核都对所有通道进行卷积，如下图所示，仅有最后一个卷积核将6个通道进行了卷积。在本次实验中，将采用每个卷积核都对所有通道进行卷积的方式，以增强特征提取能力

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	X				X	X	X			X	X	X	X		X	X
1	X	X				X	X	X			X	X	X	X		X
2	X	X	X				X	X	X			X		X	X	X
3		X	X	X			X	X	X	X			X		X	X
4			X	X	X			X	X	X	X		X	X		X
5				X	X	X			X	X	X	X		X	X	X

4. 第四层为池化层。与第二层池化层参数设置相同
5. 第五层为全连接层。上一层池化后，得到16通道， 5×5 大小的图片，因此首先展平。在经过全连接计算后，输出个数为120
6. 第六层为全连接层。输入个数120，输出个数为84
7. 第七层为输出层。输出个数为120，使用Softmax函数进行激活，最终得到在10个分类上的“概率”

网络模型的大致代码及参数设置如下：

```

1 model = Model([
2     Conv(out_channel = 6, filter_size = 5, stride = 1, padding = 2),
3     ReLU(),
4     MaxPool(filter_size = 2, stride = 2),
5     Conv(out_channel = 16, filter_size = 5, stride = 1, padding = 0),
6     ReLU(),

```

```

7     MaxPool(filter_size = 2, stride = 2),
8     Flatten(),
9     Dense(out_nchannel = 120),
10    ReLU(),
11    Dense(out_nchannel = 84),
12    ReLU(),
13    Dense(out_nchannel = 10),
14    SoftmaxCrossEntropy()
15 ], learn_rate=0.02)

```

Model 类具体实现如下：

1. 初始化。由各层进行初始化，并设置各层学习率

```

1 def __init__(self, layers, learn_rate = 0.001):
2     for layer in layers:
3         layer.learn_rate = learn_rate
4     self.layers = layers
5     self.learn_rate = learn_rate

```

2. 前向传播。若提供标签，逐层前向传播，返回最终计算分类概率；若提供标签，则额外返回损失函数的值

```

1 def forward(self, x, y = None):
2     '''
3     x is of shape (batch_size, height, width, in_nchannel)
4     y is of shape (batch_size, 10)
5     if y is None, return probs of shape (batch_size, 10)
6     if y is not None, return probs of shape (batch_size, 10) and loss
7     '''
8     n_samples = x.shape[0]
9     for layer in self.layers[:-1]:
10        x = layer.forward(x)
11    if y is None:
12        probs = softmax(x)
13        return probs
14    assert len(y) == n_samples
15    probs, loss = self.layers[-1].forward(x, y)
16    return probs, loss

```

3. 训练。根据设定的轮次和每批大小，逐批前向传播，反向传播更新各层权重，期间统计准确率、损失函数值以及最大梯度。最终计算完毕后，使用 `sklearn.metrics` 打印由预测结果与真实结果之间的效果（在各分类上的准确率，总体准确率、召回率、f1-score等）

```

1 def fit(self, x_train, y_train, x_validate, y_validate, epochs=1,
2     batch_size=32):
3     '''
4     1. train the model by epochs and batches
5     2. print validate result of each epoch
6     '''
7     n_sample = len(x_train)
8     n_batch = (n_sample - 1) // batch_size + 1
9     for epoch in range(epochs):
10        print(f"Epoch {epoch+1} =====")

```

```

11         with tqdm(total=n_batch) as t:
12             total_loss = total_acc = 0
13             for i in range(n_batch):
14                 batch = range(batch_size * i, min(batch_size * (i + 1),
n_sample))
15                 probs, loss = self.forward(x_train[batch], y_train[batch])
16                 acc = (1 / len(batch)) * np.sum(reverse_one_hot(probs) ==
reverse_one_hot(y_train[batch]))
17                 grad = self.backward()
18                 total_loss += loss
19                 total_acc += acc
20                 if (i + 1) % 32 == 0 or i + 1 == n_batch:
21                     t.set_postfix({
22                         'avg_loss': total_loss / (i + 1),
23                         'avg_accuracy': total_acc / (i + 1),
24                         'max_abs_gradient': np.max(abs(grad))
25                     })
26                     cur_n_batch = i % 32 + 1
27                     t.update(cur_n_batch)
28                 print("Validation:")
29                 validate_probs, validate_loss = self.evaluate(x_validate,
y_validate)
30                 print('loss: ', validate_loss)
31                 print(metrics.classification_report(reverse_one_hot(validate_probs),
reverse_one_hot(y_validate)))

```

4. 预测和评估函数即分类根据是否提供验证标签，返回前向传播的预测概率（预测概率及损失）

```

1 def predict(self, x, batch_size=32):
2     '''
3     return probabilities
4     '''
5     probs = []
6     n_sample = len(x)
7     n_batch = (n_sample - 1) // batch_size + 1
8     for i in tqdm(range(n_batch)):
9         batch = range(batch_size * i, min(batch_size * (i + 1), n_sample))
10        probs.append(self.forward(x[batch]))
11    return np.concatenate(probs)
12
13 def evaluate(self, x, y, batch_size=32):
14     '''
15     return probabilities and average loss of each batch
16     '''
17    probs = []
18    n_sample = len(x)
19    n_batch = (n_sample - 1) // batch_size + 1
20    total_loss = 0
21    for i in tqdm(range(n_batch)):
22        batch = range(batch_size * i, min(batch_size * (i + 1), n_sample))
23        temp_probs, loss = self.forward(x[batch], y[batch])
24        probs.append(temp_probs)
25        total_loss += loss
26    return np.concatenate(probs), total_loss / n_batch

```

卷积层

网络中各层的实现从基类 `Layer` 派生，必须保存各层原始输入（为反向传播准备），并实现前向传播与反向传播

```
1 class Layer:
2     def forward(self, x):
3         self.x = x.copy()
4     def backward(self, grad_in):
5         raise NotImplementedError
```

卷积层需要提供的参数为输出通道数、卷积核大小、步长、补白大小。

1. 初始化。设定给定参数及用以计算的权重 `w` 和 `b`

```
1 def __init__(self, out_nchannel, filter_size, stride = 1, padding = 0):
2     self.out_nchannel = out_nchannel
3     self.filter_size = filter_size
4     self.stride = stride
5     self.padding = padding
6     self.W = None
7     self.b = None
```

2. 前向传播。若权重未初始化，则将权重进行随机初始化。根据二维卷积计算公式进行计算。当使用没有快速优化过的卷积运算，使用 `generate_regions` 获取卷积计算的行号、列号以及选定区域，再使用卷积核和权重进行计算。`generate_regions` 函数具体实现如下，根据步长和卷积核大小生成包含计算信息的序列

```
1 def generate_regions(X, dim, stride):
2     '''
3     Generate regions of size dim x dim from X with stride.
4     X is of shape (batch_size, height, width, in_nchannel)
5     '''
6     assert X.shape[1] >= dim
7     assert X.shape[2] >= dim
8     for fh, h in enumerate(range(0, X.shape[1] - dim + 1, stride)):
9         for fw, w in enumerate(range(0, X.shape[2] - dim + 1, stride)):
10             yield fh, fw, np.s_[:, h:h + dim, w:w + dim, :]
```

前向传播的具体计算如下：

```
1 def forward(self, x):
2     '''
3     x is of shape (batch_size, height, width, in_nchannel)
4     '''
5     super().forward(x)
6     out_nchannel, filter_size, stride, padding = self.out_nchannel,
self.filter_size, self.stride, self.padding
7     if self.W is None:
8         self.W = np.random.randn(filter_size, filter_size, x.shape[-1],
out_nchannel) * np.sqrt(2 / (x.shape[1] * x.shape[2] * x.shape[3]))
9         self.b = np.zeros(out_nchannel)
10    W, b = self.W, self.b
11    x = np.pad(x, [(0, 0), (padding, padding), (padding, padding), (0, 0)],
'constant')
```

```

12     Wx = np.zeros((len(x), (x.shape[1] - W.shape[0]) // stride + 1,
(x.shape[2] - W.shape[1]) // stride + 1, out_nchannel))
13     for fh, fw, slice in generate_regions(x, filter_size, stride):
14         Wx[:, fh, fw, :] = np.tensordot(x[slice], W, axes=3)
15     return Wx + b

```

3. 反向传播。根据下层传播的梯度进行反向传播，最终更新权重

```

1  def backward(self, grad_in):
2      x = self.x
3      dx = np.zeros_like(x, dtype=float)
4      dw = np.zeros_like(self.W)
5      db = np.zeros_like(self.b)
6      filter_size, stride, padding = self.filter_size, self.stride,
self.padding
7      x = np.pad(x, ((0, 0), (padding, padding), (padding, padding), (0, 0)),
'constant')
8      dx_pad = np.zeros_like(x, dtype=float)
9
10     for fh, fw, slice in generate_regions(x, filter_size, stride):
11         grad_in_slice = grad_in[:, fh, fw, newaxis, newaxis, newaxis, :]
12         dx_pad[slice] += np.sum(self.W * grad_in_slice, axis=-1)
13         dw += np.sum(x[slice][..., newaxis] * grad_in_slice, axis=0)
14         db += np.sum(grad_in_slice, axis=0).squeeze()
15     dx = dx_pad[:, padding:-padding, padding:-padding, :] if padding > 0
else dx_pad
16     self.W -= dw * self.learn_rate
17     self.b -= db * self.learn_rate
18     return dx

```

池化层

池化层与卷积层比较相似，前向传播和反向传播实现如下：

```

1  def forward(self, x):
2      '''
3      x is of shape (batch_size, height, width, in_nchannel)
4      '''
5      super().forward(x)
6      filter_size, stride = self.filter_size, self.stride
7      out = np.zeros((len(x), (x.shape[1] - filter_size) // stride + 1,
8(x.shape[2] - filter_size) // stride + 1, x.shape[3]))
9      for fh, fw, slice in generate_regions(x, filter_size, stride):
10         out[:, fh, fw, :] = np.max(x[slice], axis=(1, 2))
11     return out
12
13  def backward(self, grad_in):
14      x = self.x
15      filter_size, stride = self.filter_size, self.stride
16      dx = np.zeros_like(x, dtype=float)
17      for fh, fw, slice in generate_regions(x, filter_size, stride):
18         xs = x[slice]
19         indices = np.indices((xs.shape[0], xs.shape[-1]))
20         max_indices = (indices[0, ] + np.unravel_index(
21             xs.reshape((xs.shape[0], -1, xs.shape[-1])).argmax(axis=1),
22             xs.shape[1:-1]) + (indices[1, ], )

```

```

23     mask = np.zeros_like(xs)
24     mask[max_indices] = 1
25     dx[slice] += mask * grad_in[:, fh, newaxis, fw, newaxis, :]
26     return dx

```

展平

展平仅进行简单的形状变换。将多维数组展平为1维（这里为了突出展平的作用，所述“维度”没有包括表示图片数量的第一维）

```

1  class Flatten(Layer):
2      def forward(self, x):
3          '''
4          x is of shape (batch_size, height, width, in_nchannel)
5          out is of shape (batch_size, -1)
6          '''
7          super().forward(x)
8          return x.reshape((len(x), -1))
9      def backward(self, grad_in):
10         return grad_in.reshape(self.x.shape)

```

全连接层

全连接层将各输入进行线性加权，最终按输出维度进行输出

```

1  class Dense(Layer):
2      def __init__(self, out_nchannel):
3          self.out_nchannel = out_nchannel
4          self.W = None
5          self.b = None
6
7      def forward(self, x):
8          '''
9          x is of shape (batch_size, in_nchannel)
10         out is of shape (batch_size, out_nchannel)
11         '''
12         super().forward(x)
13         in_nchannel = x.shape[-1]
14         out_nchannel = self.out_nchannel
15         if self.W is None:
16             self.W = np.random.randn(in_nchannel, out_nchannel) * np.sqrt(
17                 2 / in_nchannel)
18             self.b = np.zeros(out_nchannel)
19         w, b = self.W, self.b
20         return np.dot(x, w) + b
21
22     def backward(self, grad_in):
23         x = self.x
24         dx = np.dot(grad_in, self.W.T)
25         self.W -= np.dot(x.T, grad_in) * self.learn_rate
26         self.b -= np.sum(grad_in, axis=0) * self.learn_rate
27         return dx

```

激活函数

ReLU函数的前向传播与反向传播实现如下：

```
1 class ReLU(Layer):
2     def __init__(self):
3         self.mask = None
4
5     def forward(self, x):
6         super().forward(x)
7         self.mask = x <= 0
8         out = x.copy()
9         out[self.mask] = 0
10        return out
11
12    def backward(self, grad_in):
13        dx = grad_in.copy()
14        dx[self.mask] = 0
15        return dx
```

Softmax函数

本实验使用softmax函数对最终全连接层的84个输出进行10“分类”（因为Softmax将输出值映射到0~1区间，因此可以作为“分类”使用）。前向传播与反向传播实现如下：

```
1 class SoftmaxCrossEntropy(Layer):
2     def __init__(self):
3         self.grad = None
4
5     def forward(self, x, y):
6         '''
7         x is of shape (batch_size, in_nchannel)
8         y is of shape (batch_size, in_nchannel)
9         return probs of shape (batch_size, in_nchannel) and loss
10        '''
11        super().forward(x)
12        m = x.shape[0]
13        probs = softmax(x)
14        loss = (-1 / m) * np.log(probs[y==1]).sum()
15        self.grad = (probs - y) / m
16        return probs, loss
17
18    def backward(self, grad_in):
19        return self.grad
```

实验环境

实验所需第三方模块及版本如下：

Packet	Version
Python	3.8.13
numpy	1.23.4
scikit-learn	1.1.3
matplotlib	3.6.2
tqdm	4.64.1

实验结果与分析

设置训练轮数为2，批大小为32。训练过程中准确率和损失函数值，以及最终验证结果如下：

第一轮：

```
Epoch 1 =====
100%|██████████| 1875/1875 [06:49<00:00, 4.58it/s, avg_loss=0.334,
avg_accuracy=0.896, max_abs_gradient=0.00156]
Validation:
100%|██████████| 313/313 [00:23<00:00, 13.21it/s]
loss: 0.13581246946247835
      precision    recall  f1-score   support

     0           0.99      0.94      0.97       1032
     1           0.99      0.96      0.98       1166
     2           0.94      0.98      0.96        989
     3           0.94      0.97      0.95        981
     4           0.99      0.95      0.97       1026
     5           0.97      0.94      0.96        924
     6           0.94      0.99      0.97        907
     7           0.91      0.98      0.94        952
     8           0.93      0.95      0.94        952
     9           0.96      0.90      0.93       1071

 accuracy          0.96          10000
  macro avg       0.96      0.96      0.96       10000
weighted avg       0.96      0.96      0.96       10000
```

第二轮：

```

Epoch 2 =====|
100%|██████████| 1875/1875 [06:49<00:00, 4.58it/s, avg_loss=0.105,
avg_accuracy=0.967, max_abs_gradient=0.000586]
Validation:
100%|██████████| 313/313 [00:22<00:00, 14.18it/s]loss: 0.08531186600546471
      precision    recall  f1-score   support

         0           0.99           0.96           0.98           1012
         1           0.99           0.97           0.98           1156
         2           0.95           0.99           0.97            998
         3           0.97           0.96           0.96           1023
         4           0.99           0.97           0.98            996
         5           0.99           0.95           0.97            926
         6           0.96           0.99           0.97            930
         7           0.96           0.99           0.97            999
         8           0.95           0.97           0.96            956
         9           0.96           0.96           0.96           1004

   accuracy                                0.97           10000
macro avg           0.97           0.97           0.97           10000
weighted avg        0.97           0.97           0.97           10000

```

注意到在第一轮的准确率随着批次增加逐渐上升，最终在验证集上的总体准确率达到96%。而进一步进行第二轮训练时，准确率提升已经不大，最终在验证集上的总体准确率达到97%。

总结

通过本次实验，对卷积神经网络的特点和实现有了深刻体会，对最终实验结果的评估和优化有了直观了解。机器学习应用广泛，前景广阔，学习之路才刚开始。

参考资料

1. [LeNet-by-numpy](#)
2. Y. Lecun, L. Bottou, Y. Bengio and P. Haffner, "Gradient-based learning applied to document recognition," in Proceedings of the IEEE, vol. 86, no. 11, pp. 2278-2324, Nov. 1998, doi: 10.1109/5.726791.